

Klasyfikacja danych dźwiękowych przy pomocy metod uczenia głębokiego

Projekt na przedmiot UNiUM

Michał Grzegory, Paweł Możaryn

Styczeń 2026

1 Wstęp

1.1 Cel projektu


Celem projektu jest zbudowanie modelu uczenia głębokiego, który będzie klasyfikował utwór muzyczny do jednego z ośmiu gatunków. Zadanie to nie należy do najłatwiejszych - w rzeczywistości ciężko jest jednoznacznie przyporządkować utwór muzyczny do jednego gatunku.

Dane nie są ani tabelaryczne, ani nie mają jasno określonej dyskretnej struktury czasowej - pojawia się pytanie, w jaki sposób sprepować je do postaci, na której jest w stanie nauczyć się model.

1.2 Plan działania oraz podstawowe definicje

W tym projekcie jako medium między światem muzycznym a cyfrowym wykorzystamy *spektrogram*:

Spektrogram to reprezentacja dźwięku w domenie czas-częstotliwość. Zamiast patrzeć na sygnał audio jako na jednowymiarową falę $x[t]$, dzielimy go na krótkie fragmenty (okna czasowe) i dla każdego fragmentu liczymy, jakie częstotliwości są w nim obecne. Technicznie rzecz biorąc robimy to przez krótkookresową transformatę Fouriera. W tym projekcie wykorzystamy tzw. **MEL-Spektrogram**, czyli spektrogram w którym częstotliwości zbierane są na naturalniej odbieranej przez człowieka skali MEL. (Dokonyjemy w końcu klasyfikacji wytworów człowieka!)



Rysunek 1: Spektrogram (dół) oraz oscylogram(góra). Źródło; Philip S. Lobel

Obraz zamiast dźwięku jest lepiej przystosowany do obróbki przez model - jest to w końcu trójwymiarowa tablica (trzecim wymiarem jest kolor, do wyrażenia którego stosuje się wartości RGB)

Naszą propozycją na obróbkę tego typu danych jest *Splotowa sieć neuronowa*:

Splotowa sieć neuronowa to rodzaj głębokiej sieci neuronowej zaprojektowanej do przetwarzania danych o strukturze siatki, takich jak obrazy czy właśnie nasze spektrogramy. Jej kluczowym elementem są warstwy splotowe (konwolucyjne), które wykorzystują przesuwalne filtry do wykrywania lokalnych wzorców, takich jak krawędzie czy kształty, co mamy nadzieję pomoże nam w wykonaniu tego projektu.

2 Preprocessing

2.1 Źródło danych

Źródłem naszych danych będzie internetowa baza danych muzycznych **Free Music Archive**, a konkretnie folder `fma_small`, zawierający 8000 plików `.mp3` z utworami ośmiu różnych gatunków: **Electronic, Experimental, Folk, Hip-Hop, Instrumental, International, Pop, Rock**. Pliki mają długość 30s. Nie używamy żadnych gotowych statystyk dostępnych na stronie FMA. Gatunki przypisane do plików zawarte są w `tracks.csv`

2.2 Metodologia

1. wszystkie spektrogramy wygenerowane zostały całkowicie w fazie preprocessingu - modele będą miały styczność tylko z gotowymi spektrogramami. Podejścia polegające na *wbudowaniu w model* elementu przekształcającego muzykę na tablice zostało odrzucone, ze względu na olbrzymi koszt czasowy (w trakcie treningu model spotyka się bowiem z każdą obserwacją wiele razy, co więcej trening często jest powtarzany dla różnych hiperparametrów)
2. z jednego utworu wygenerowano **3 spektrogramy**, z 3 losowo wybranych, ale nie nachodzących na siebie fragmentów 30-sekundowego utworu. Przetwarzanie całości byłoby zbyt kosztowne czasowo i zbędne (muzyka ma okresową strukturę), a przycięcie każdego utworu do 3 sekund wiązałoby się ze stratą 90% danych!
3. Spektrogramy zostały zapisane w formacie `.npy`, ze względu na to że jest on najbliższy używanemu przez modele formatowi `torch.tensor`
4. Wszystkie spektrogramy zostały wykonane w ten sam sposób opisany poniżej. Wynikowe pliki `.npy` mają stały rozmiar **128 x 128**

2.3 Sposób wytworzenia spektrogramów

Spektrogramy zostały wytworzone przy użyciu bibliotek `pydub.Audiosegment` oraz `librosa`.

2.3.1 Jak poszczególne parametry wpływają na spektrogram?

Oś X (czas).


- `seconds` — długość wycinka sygnału (w sekundach). Sama oś X zależy też od pozostałych parametrów.
- `sr` — częstotliwość próbkowania; maksymalna reprezentowalna częstotliwość to $\frac{sr}{2}$ (granica Nyquista). Liczba próbek w wycinku to `seconds · sr`.
- `hop_length` — krok przesuwu okna na którym wykonujemy transformatę Fouriera w próbkach; mniejszy `hop_length` daje gęstsza siatkę w czasie (więcej ramek).

Oś Y (częstotliwość).

- `n_mels` — liczba pasm (kubelków) w skali mel, czyli rozdzielczość osi częstotliwości.
- `f_min`, `f_max` — ograniczenie analizowanego zakresu częstotliwości.
- `n_fft` — długość okna FFT (w próbkach), czyli ile próbek obejmuje pojedyncza analiza widma. Większe `n_fft` daje lepszą rozdzielczość częstotliwości, ale gorszą rozdzielczość czasową (i większy koszt obliczeń).

2.4 Użyte ustawienia i przykładowy wynik

```
seconds: float = 3.0,  
sr: int = 22050,  
n_mels: int = 128,  
n_fft: int = 2048,  
hop_length: int = 512,  
fmin: float = 20.0,  
fmax: float | None = 8000.0,  
top_db: float = 80.0,  
time_bins: int = 128,
```



Rysunek 2: Spektrogramy oraz użyte parametry

2.5 Dźwiękowe dane tabelaryczne

Przy okazji tworzenia każdego spektrogramu zebrano na jego podstawie statystyki.

- dotyczące średniej częstotliwości występującej na 30 kolejnych przedziałach czasowych o długości 0.1s.
- % pikseli o bardzo małej częstotliwości (jak bardzo 'biały' jest spektrogram)
- globalną średnią po skwadratowaniu każdego elementu

Niezależnie od spektrogramów zebrano również inne cechy dźwiękowe.

Każdy z 30 sekundowych utworów przekonwertowaliśmy w sygnał **mono**, z którego następnie wyekstrahowaliśmy **średnią** i **odchylenie standardowe** różnych charakterystyk dotyczących dźwięku, między innymi:

- Ilość energii zawartej w utworze.
- Częstość przecinania zera przez falę dźwiękową.
- Zbiór 13 współczynników naśladujących ludzką percepcję słuchu.
- Zestaw 12 wartości odpowiadającym tonom muzycznym (np. C, G, D...).

3 Eksploracyjna Analiza Danych (EDA)

W tej sekcji przedstawimy proces analizy zbioru danych muzycznych. Badania przeprowadziliśmy na danych tabelarycznych wspomnianych w sekcji 2.4. Warto zaznaczyć, że zbiór *fma_small* zawiera zbalansowane klasy - każda ma 1000 reprezentantów w 8000 zbiorze - nie ma zatem potrzeby ważenia obserwacji.

3.1 Dane statystyczne ze spektrogramów

Zaczelismy od przekonwertowania danych na pliki .npy. Potem wyekstrahowalismy wybrane przez nas statystyki z każdego z urywków audio, między innymi średnią czy odchylenie standardowe. Dodatkowo uwzględniliśmy w 30 odstępach czasowych zmienne dotyczące średniej częstotliwości na każdym z nich.

W ramach analizy wykonaliśmy następujące:

- Wykresy pudełkowe pokazujące rozkłady danych statystyk.
- Histogramy ukazujące cechy globalnie.
- Macierz korelacji cech.
- Wstępne przetestowanie danych na typowym modelu KNN.
- Sprawdzenie PCA dla 2 wymiarów, by przekonać się, czy nasze dane nie będą łatwo separowalne.

Zrezygnowaliśmy z wyświetlania tutaj wyników całej EDA przez obszerność i dużą liczbę wykresów, będą one zamieszczone w odpowiednim pliku. Opiszemy za to krótko wnioski z ich analizy. Wykresy pudełkowe pokazały, że niektóre z cech różnicują w małym stopniu nasze gatunki oraz to, że mamy do czynienia z niewielką ilością wartości odstających. Histogramy pokazały, że globalne rozkłady są asymetryczne i dosyć zróżnicowane. Macierz korelacji pokazała, że większość cech jest niestety silnie skorelowana. Wstępny test na modelu KNN dał słaby wynik pokroju 25 procent accuracy na zbiorze testowym. Dwuwymiarowe PCA wykazało, że dane są wysoko wymiarowe - kombinacje liniowe atrybutów słabo tłumaczą zmienność klas.

3.2 Dane statystyczne z analizy fali dźwiękowej

W ramach analizy w tej części podobnie jak w poprzedniej zdecydowaliśmy się na wykonanie:

- Wykresów pudełkowych pokazujących rozkłady danych cech.
- Histogramów ukazujących cechy globalnie.
- Macierzy korelacji cech.
- Wstępnych testów danych na typowym modelu KNN.

W tym wariancie również rezygnujemy z wyświetlania z tych samych powodów co powyżej. Wnioski z ich analizy: Wykresy pudełkowe podobnie jak ostatnio pokazały, że cechy różnicują gatunki do pewnego stopnia, tu również mamy część outlierów. Histogramy okazały się ciekawsze, były zróżnicowane i również asymetryczne. W macierzy korelacji okazało się, że większość cech jest słabo skorelowana, co jest dobrą dla nas informacją. Wstępny test na modelu KNN dał solidny wynik pokroju 47 procent accuracy na zbiorze testowym.

4 Modelowanie - wprowadzenie teoretyczne

Naszym celem jest znalezienie zespołu parametrów sieci neuronowej, które na danych treningowych minimalizują odpowiednią funkcję straty. W zadaniu klasyfikacji wieloklasowej używaną funkcją jest **Cross-Entropy-Loss**.

Optymalizacja parametrów odbywa się poprzez różne wariacje metody **Gradient Descent**. W uczeniu maszynowym popularną metodą optymalizacji jest **Adaptive Moment Estimation, ADAM**. Metoda ta korzysta z historii ruchów w przestrzeni parametrów i penalizuje ruchy, które znacząco odbiegają od obranej dotychczas trajektorii.

W zwykłym uczeniu maszynowym mogliśmy (przynajmniej w większości przypadków) pozwolić sobie na aproksymację gradientu funkcji straty na **całości danych treningowych**. W uczeniu głębokim ilości danych oraz skomplikowanie funkcji modelu (część funkcji straty) rośnie. Dlatego też gradient aproksymuje się za pomocą małej części danych, zwanej *batch*. Jeden *batch* zawiera w tym projekcie 64 obserwacje. Jedna *epoka* pokrywa batchami całe dane treningowe i wiąże się z ich uwczesnym przetasowaniem.

Na *epoki* można patrzeć także jako *checkpointy* w procesie treningu, po których monitorujemy jak dobry jest nasz model w tym momencie.

5 Modelowanie - dane tabelaryczne

W tej części przetestujemy jak *modelowalna* jest muzyka za pomocą danych liczbowych tabelarycznych.

Do modelowania danych tabelarycznych użyto prostej 3-warstwowej sieci neuronowej o podanej strukturze.



```
nn.Linear(input_dim, 64),
nn.BatchNorm1d(64),
nn.ReLU(),
nn.Dropout(0.3), # Dropout wyłącza wynik neuronu z poprzedniej warstwy
z prawdopodobieństwem 0.3 - przeciwdziała przeuczeniu.
nn.Linear(64, 32),
nn.BatchNorm1d(32),
nn.ReLU(),
nn.Linear(32, output_dim)
```

Ta część stanowi dla nas jedynie wyjście dla bardziej złożonego modelowania za pomocą sieci konwolucyjnych i może być traktowana jako część **EDA**. Dlatego też analiza jest ograniczona - przeprowadzono jeden trening, ale w 40 epokach.

Raportujemy:

- *accuracy* na zbiorach testowym i treningowym w kolejnych epokach
- *confusion matrix*, po zakończonym treningu.
- podstawowe miary używane w zadaniu klasyfikacji.



5.1 Dane statystyczne ze spektrogramów - wynik modelowania przez MLP



Klasa	Precyzja	Czułość	Wynik F1	Liczebność
Electronic	0.32	0.19	0.24	600
Experimental	0.27	0.14	0.18	599
Folk	0.32	0.30	0.31	600
Hip-Hop	0.39	0.54	0.46	597
Instrumental	0.35	0.53	0.42	599
International	0.24	0.28	0.26	600
Pop	0.18	0.08	0.11	600
Rock	0.38	0.57	0.46	599
Accuracy	0.33	0.33	0.33	4794
Macro Avg	0.31	0.33	0.31	4794
Weighted Avg	0.31	0.33	0.30	4794

Jak widzimy model poradził sobie poprostu słabo, jest to spowodowane tym, że wybrane w tym podejściu statystyki (patrz **sekcja 2.5**) nie są przystosowane do opisywania danych dźwiękowych. Warto dodać, że wyraźnie gorzej radzi on sobie z klasami **Experimental** i **Pop**. Może kolejna próba okaże się lepsza.

5.2 Dane dźwiękowe - wynik modelowania przez MLP



Klasa	Precyzja	Czułość	Wynik F1	Liczebność
Electronic	0.51	0.52	0.51	200
Experimental	0.54	0.31	0.39	200
Folk	0.56	0.64	0.60	200
Hip-Hop	0.52	0.62	0.56	199
Instrumental	0.52	0.61	0.56	200
International	0.47	0.51	0.49	200
Pop	0.34	0.23	0.28	200
Rock	0.61	0.68	0.64	200
Accuracy	0.51	0.51	0.51	1599
Macro Avg	0.51	0.51	0.50	1599
Weighted Avg	0.51	0.51	0.50	1599

Model oparty na cechach przystosowanych do danych dźwiękowych (patrz **sekcja 2.5, dół**) poradził sobie z naszym zadaniem zaskakująco dobrze. Ponadto jak widać po wykresie nie ma on znacznej tendencji do przeuczenia. Warto dodać, że również tak jak model na danych statystycznych ma on problem z poprawną identyfikacją gatunków **Experimental** i **Pop**, co może świadczyć o tym, że utwory z nich są po prostu podobne do tych z innych klas.

6 Modelowanie - spektrogramy

W tej sekcji modele będą trenowane na zebranych (patrz **sekcja 2.2**) spektrogramach.

6.1 Metodologia

Tu monitorujemy

- wartość funkcji straty po każdej epoce na zbiorze testowym i treningowym
- tak samo dokładność
- każdy trening powtarzamy 3 razy
- raportujemy macierz pomyłek oraz podstawowe miary dla klasyfikacji **dla ostatniego treningu z epoki, w której osiągnięto średnio najmniejszą funkcję straty**
- Każdy trening odbywa się na całości 30 epok aby sprawdzać potencjał modelu do **przeuczenia**
- **Liczebność**, czyli ile obserwacji danej klasy było w zbiorze testowym (wyniki są mało miarodajne dla bardzo niebalansowanych klas)


6.2 Test dla sieci MLP na danych spłaszczonych

Będziemy teraz działać na naszych spektrogramach. Jak wiemy sieć MLP jest przystosowana do przyjmowania wektorów, a nie struktur wielowymiarowych. tak więc możemy spodziewać się przez to nie najlepszych wyników, jednak zawsze warto sprawdzić.

6.2.1 Wyniki

		Klasa Przewidywana							
		Electronic	Experimental	Folk	Hip-Hop	Instrumental	International	Pop	Rock
Klasa Rzeczywista	Electronic	287	83	3	2	59	0	0	166
	Experimental	109	186	6	2	135	1	0	158
	Folk	64	127	98	0	197	0	0	114
	Hip-Hop	308	65	1	15	12	0	0	196
	Instrumental	64	106	26	0	315	0	0	89
	International	140	204	32	2	92	0	0	130
	Pop	137	108	20	4	57	0	0	274
	Rock	61	46	5	1	55	0	0	432

SpectrogramMLP | optimiser: Adam | runs=3



Klasa	Precyzja	Czułość	Wynik F1	Liczebność
Electronic	0.245	0.478	0.324	600
Experimental	0.201	0.312	0.244	597
Folk	0.513	0.163	0.248	600
Hip-Hop	0.577	0.025	0.048	597
Instrumental	0.342	0.525	0.414	600
International	0.000	0.000	0.000	600
Pop	0.000	0.000	0.000	600
Rock	0.277	0.720	0.400	600
Accuracy	0.278	0.278	0.278	4794
Macro Avg	0.269	0.278	0.210	4794
Weighted Avg	0.269	0.278	0.210	4794

6.2.2 Wnioski

Jak widzimy model szybko się przeucza i jest niestabilny. Jest tak dlatego, że na wejściu model ma wektor długości 128x128, w którym struktura czasowa oraz dwuwymiarowa jest rozbita. Model uczy się losowych fluktuacji w danych, zamiast prawdziwych zależności.

Widzimy, że klasy **International**, **Pop** sprawiają modelowi największy problem. W większości myli je on z **Rock**, zapewne tak jak większość ludzi.


Z drugiej strony najlepiej przewiduje on takie klasy jak **Electronic** i **Instrumental**. **Rock** ma wysoki *True Positive Rate*, ale też wysoki *False Positive Rate*.

6.3 Test sieci konwulucyjnej CNN

Dzięki warstwom konwulucyjnym sieci typu CNN są dużo bardziej przystosowane do danych dwuwymiarowych niż na przykład MLP.

Dlatego też spodziewamy się lepszych wyników.

6.3.1 Wyniki



		Klasa Przewidywana							
		Electronic	Experimental	Folk	Hip-Hop	Instrumental	International	Pop	Rock
Klasa Rzeczywista	Electronic	452	73	4	7	32	10	7	15
	Experimental	76	312	19	2	100	33	13	42
	Folk	25	97	291	1	99	31	16	40
	Hip-Hop	248	46	0	203	22	33	24	21
	Instrumental	64	100	24	3	357	12	7	33
	International	80	69	56	9	20	325	22	19
	Pop	138	117	32	10	76	43	60	124
	Rock	49	99	14	0	44	25	28	341

Klasa	Precyzja	Czułość	Wynik F1	Liczebność (Support)
Electronic	0.399	0.753	0.522	600
Experimental	0.342	0.523	0.413	597
Folk	0.661	0.485	0.560	600
Hip-Hop	0.864	0.340	0.488	597
Instrumental	0.476	0.595	0.529	600
International	0.635	0.542	0.585	600
Pop	0.339	0.100	0.154	600
Rock	0.537	0.568	0.552	600
Accuracy	0.488	0.488	0.488	4794
Macro Avg	0.532	0.488	0.475	4794
Weighted Avg	0.532	0.488	0.475	4794


6.3.2 Wnioski

Model CNN poradził sobie z zadaniem już znacznie lepiej. Nie ma on aż tak dużej tendencji do przeuczenia oraz na danych testowych daje wyniki nawet w okolicach 0.45. Martwić mogą jednak niestabilne wartości funkcji straty na zbiorze testowym. Jest to spowodowane głębokością sieci i problemami z numeryczną aproksymacją gradientu. Widzimy poprawę również w macierzy błędów, w której wszystkie klasy poza **Pop** dają już przyzwoite wyniki. Na przykład klasa **Electronic** jest już przyporządkowywana z 75 procentową dokładnością.

6.4 CRNN Convolutional Recurrent Neural Network

Rozważamy ten model ponieważ dzięki rekurencyjnej strukturze ma on potencjał na lepsze obrobienie danych o strukturze czasowej.

6.4.1 Wyniki



		Klasa Przewidywana							
		Electronic	Experimental	Folk	Hip-Hop	Instrumental	International	Pop	Rock
Klasa Rzeczywista	Electronic	348	30	30	71	39	15	60	7
	Experimental	44	218	85	44	85	18	84	19
	Folk	7	39	445	5	34	4	62	4
	Hip-Hop	42	9	16	419	14	13	77	7
	Instrumental	37	44	108	11	324	10	50	16
	International	31	21	163	44	12	251	74	4
	Pop	59	22	134	58	54	12	207	54
	Rock	20	36	69	2	42	9	211	211

Klasa	Precyzja	Czułość	Wynik F1	Liczebność
Electronic	0.592	0.580	0.586	600
Experimental	0.520	0.365	0.429	597
Folk	0.424	0.742	0.539	600
Hip-Hop	0.641	0.702	0.670	597
Instrumental	0.536	0.540	0.538	600
International	0.756	0.418	0.539	600
Pop	0.251	0.345	0.291	600
Rock	0.655	0.352	0.458	600
Accuracy	0.505	0.505	0.505	4794
Macro Avg	0.547	0.505	0.506	4794
Weighted Avg	0.547	0.505	0.506	4794


6.4.2 Wnioski

Model ma duże tendencje do przeuczenia, zwraca *stabilniejsze* wyniki, jednak nie są one szczególnie zadowalające. Co ciekawe, model znacznie lepiej radzi sobie z naszą nieszczęsną kategorią **Pop** przyporządkowując poprawnie około 0.33 z rekordów (wcześniej było zero!). Dodatkowo dobrze poradził sobie z klasą **Folk**. Wynik jest więc porównywalny z CNNem, ale jednak co ciekawe oba modele mylą się na różnych kategoriach.

6.5 ResNet


Poprzednie sieci osiągnęły *akceptowalny* wynik, ale były bardzo niestabilne. Jest to w zgodzie z teorią, która mówi że w bardzo głębokich sieciach ewentualne błędy w liczeniu gradientu nawarstwiają się. Dlatego wprowadzamy sieć z połączeniami rezyduálnymi.

Residual Block to zespół warstw sieci neuronowej z bezpośrednim połączeniem łączącym początek i koniec takich warstw, zwanym *połączeniem rezydualnym*. Obecność takich połączeń sprawia, że przepływ informacji między warstwami jest stabilniejszy. Można zbudować głębszą sieć, która pozostaje numerycznie stabilna!



Rysunek 3: Schemat bloku rezydualnego. Źródło: Wikipedia $\text{ResBlock}(x) = \text{Inner}(x) + x$

6.5.1 Wyniki



		Klasa Przewidywana							
		Electronic	Experimental	Folk	Hip-Hop	Instrumental	International	Pop	Rock
Klasa Rzeczywista	Electronic	424	47	12	27	30	10	24	26
	Experimental	52	242	51	19	82	43	38	70
	Folk	15	38	379	5	43	32	33	55
	Hip-Hop	126	19	6	377	12	11	28	18
	Instrumental	54	45	68	8	331	19	25	50
	International	59	21	74	49	18	301	30	48
	Pop	116	25	76	59	49	33	80	162
	Rock	24	44	34	9	20	13	58	398

Klasa	Precyzja	Czułość	Wynik F1	Liczebność
Electronic	0.487	0.707	0.577	600
Experimental	0.503	0.405	0.449	597
Folk	0.541	0.632	0.583	600
Hip-Hop	0.682	0.631	0.656	597
Instrumental	0.566	0.552	0.559	600
International	0.652	0.502	0.567	600
Pop	0.253	0.133	0.175	600
Rock	0.481	0.663	0.558	600
Accuracy	0.528	0.528	0.528	4794
Macro Avg	0.521	0.528	0.515	4794
Weighted Avg	0.521	0.528	0.515	4794

6.5.2 Wnioski

Wykresy potwierdzają nasze przypuszczenia. Model cechuje się dużo większą stabilnością wyników. Co ciekawe, dalej klasa **Pop** przysparza nam najwięcej błędów. Reszta klas jest już przyporządkowana na przyzwoitym poziomie około 60 procent. Model wydaje się najodporniejszy na przeuczanie.

7 Podsumowanie projektu

W projekcie podjęliśmy się zadania klasyfikacji utworów muzycznych do ośmiu gatunków, wykorzystując zbiór FMA oraz transformację sygnału do postaci Mel-spektrogramów. Rozpoczęliśmy od analizy danych tabelarycznych, gdzie zaskakująco dobre wyniki osiągnęła sieć MLP oparta na cechach fali dźwiękowej. Następnie przeszliśmy do uczenia głębokiego na obrazach - naszych spektrogramach, testując podstawową sieć MLP, która jednak szybko ulegała przeuczeniu i gubiła strukturę danych. Wprowadzenie splotowych sieci neuronowych znacząco poprawiło jakość klasyfikacji, skuteczniej wyciągając wzorce wizualne ze spektrogramów. Eksperyment z siecią rekurencyjną CRNN pozwolił na lepsze uwzględnienie zależności czasowych, co pomogło w rozpoznawaniu sprawiającej problemy dotychczasowym modelom klasy Pop. Najsensowniejszym rozwiązaniem okazała się architektura ResNet, która dzięki połączeniom rezyduacyjnym zapewniła największą stabilność procesu uczenia. Mimo zastosowania zaawansowanych architektur, gatunki takie jak Pop i Experimental pozostały wyzwaniem najpewniej ze względu na swoje podobieństwo do innych klas. Ostatecznie projekt wykazał, że dla danych muzycznych kluczowe jest zastosowanie modeli głębokich odpornych na zanikanie gradientu, takich jak ResNet, ale podejście z cechami dźwiękowymi też nie jest złym pomysłem. Najlepsze modele osiągnęły accuracy w okolicach 53 procent, przy czym szczególnie wysokie wyniki odnotowaliśmy dla gatunków Rock oraz Electronic. Całość badań potwierdza, że traktowanie dźwięku jako obrazu jest metodą skuteczną, o ile używamy przy tym odpowiedniej architektury sieci.

8 Implementacja oraz pliki

- do budowy modeli użyto biblioteki **pytorch**, do obróbki dźwięku **pydub** oraz **librosa**
- `preprocess0.ipynb` plik skupia się na przekształceniu `tracks.csv` na wewnętrzne `labels.csv`, które odpowiada utworom z `fma_small`
- `preprocess1.ipynb` plik zawiera funkcje tworzącą spektrogramy oraz zbierającą z nich statystyki. Wynik to folder `spectrograms` oraz plik `good_labels` zawierający klasy dla utworów które dało się przerobić na spektrogramy (niektóre dane miały błędy!) `spectrogram_stats.csv`
- `preprocess2.ipynb` plik zawiera osobną funkcję wykorzystującą **librosa** do ekstrakcji cech utworów
- `models_librosa_avg.ipynb` plik zawiera tworzenie, trening oraz ewaluację modeli
- `spectrogram_stats` Statystyki wyciągnięte ze spektrogramów.
- `EDA_na_spectrogram_stats.ipynb` zawiera eksploracyjną analizę danych na danych pochodnych ze spektrogramów
- `extracted.csv` zawiera cechy wyciągnięte bezpośrednio z całości 30 sekundowych utworów za pomocą *librosy*
- `EDA_na_extracted.ipynb` zawiera eksploracyjną analizę danych na danych dźwiękowych
- folder `wyniki_avg` zawierający wyniki przedstawione w powyższym raporcie oraz wizualizacje struktur modeli.

- `test_na_extracted.ipynb` zawiera wynik modelowania danych dźwiękowych
- `test_na_spectrogram_stats.ipynb` zawiera wynik modelowania danych statystycznych ze spektrogramów.

NIE przesyłamy plików `fma_small` oraz `spectrograms`, ponieważ mają one olbrzymie rozmiary.

9 Podziękowania

Specjalne podziękowania należą się

- Michałowi Grzegoremu
- Pawłowi Możarynowi
- Polskiej Akademii Nauk
- muzykom z całego świata

Bez nich ten projekt nie miałby szansy na powodzenie.